

Machine Learning para el Análisis y Predicción de Valor de Inmuebles mediante un enfoque de sistemas inteligentes

Misael André Quincho Blas, Bachiller¹, Joaquín Ricardo Conde Espiritu, Bachiller², Jamil Andre Baca Melendez, Bachiller³, Faviana Yovanna Valcarcel Ramos, Bachiller⁴, Karen Rubid Cotrina Mena, Bachiller⁵
1,2,3,4,5Universidad Privada del Norte, Perú, n00298120@upn.pe, n00321594@upn.pe, n00324942@upn.pe,
n00320748@upn.pe, n00331996@upn.pe
Carla Felicia Abregu Marcos, Docente. Universidad Privada del Norte, Perú, N00315034@upn.pe,

SISTEMAS INTELIGENTES Y MACHINE LEARNING

Comentado [RMLM1]: Debe estar la lista de los integrantes del equipo y docente del curso

Resumen–

El mercado inmobiliario en Perú juega un papel clave en las decisiones de inversión, financiamiento y planificación urbana. Los métodos tradicionales de tasación de inmuebles, que dependen de la experiencia de los tasadores y el uso de comparables, a menudo sufren de subjetividad, lo que genera inconsistencias en los precios finales. Con la creciente disponibilidad de registros transaccionales y datos macroeconómicos, como los proporcionados por el Banco Central de Reserva del Perú (BCRP), surge la oportunidad de aplicar modelos de machine learning para predecir los precios de las propiedades de manera objetiva y precisa.

Este proyecto tiene como objetivo diseñar e implementar un modelo predictivo para estimar el precio de venta de inmuebles en Perú (1998-2025), basándose en atributos físicos, ubicación y variables macroeconómicas. Se utilizan algoritmos de aprendizaje supervisado, como Regresión Lineal, Árboles de Decisión y K-Nearest Neighbors (KNN), para capturar relaciones complejas entre las variables y mejorar la precisión de las valoraciones. Al adaptar metodologías internacionales al contexto peruano, este modelo busca contribuir a un mercado inmobiliario más transparente y eficiente.

Palabras clave: *Predicción inmobiliaria, Tasación automatizada, Aprendizaje supervisado, Modelos predictivos, Análisis de datos inmobiliarios.*

Abstract—

The real estate market in Peru plays a significant role in investment decisions, financing, and urban planning. Traditional property valuation methods, relying on the experience of appraisers and comparables, often suffer from subjectivity, leading to inconsistencies in final pricing. With the growing availability of transactional records and macroeconomic data, such as those provided by the Central Reserve Bank of Peru (BCRP), there is an opportunity to apply machine learning models to predict property prices objectively and accurately.

This project aims to design and implement a predictive model to estimate the sale price of properties in Peru (1998-2025) based on physical attributes, location, and macroeconomic variables. Supervised learning algorithms, including Linear Regression, Decision Trees, and K-Nearest Neighbors (KNN), are utilized to capture complex relationships between variables, enhancing the precision of valuations. By adapting international methodologies to the Peruvian context, this model seeks to contribute to a more transparent and efficient real estate market.

Keywords: *Real estate prediction, Automated appraisal, Supervised learning, Predictive models, Real estate data analysis.*

I. INTRODUCCION

A nivel mundial, la digitalización del sector inmobiliario ha impulsado el desarrollo de herramientas automatizadas para la estimación del valor de bienes raíces, conocidas como *Automated Valuation Models* (AVM). Estas soluciones integran grandes volúmenes de datos con técnicas avanzadas de inteligencia artificial, permitiendo realizar valoraciones más precisas, rápidas y transparentes. Como resultado, diversos mercados internacionales han incorporado modelos predictivos basados en Machine Learning como parte fundamental de sus procesos de tasación y análisis inmobiliario.

En el caso del Perú, el mercado inmobiliario constituye una actividad económica clave al articular decisiones de inversión, financiamiento y vivienda familiar. Sin embargo, los métodos tradicionales de tasación utilizados actualmente se basan en la experiencia del tasador y en la comparación con propiedades similares, lo que introduce un alto grado de subjetividad y genera inconsistencias en los precios finales. Además, no existen modelos de valoración automatizados basados en datos reales de mercado, lo que limita la precisión de las estimaciones y la transparencia de las operaciones inmobiliarias.

La creciente disponibilidad de registros transaccionales y series macroeconómicas, como el Indicador de Precios de Venta de Departamentos del Banco Central de Reserva del Perú (BCRP), abre la oportunidad de aplicar algoritmos de aprendizaje supervisado para identificar patrones entre características físicas (área, número de habitaciones, baños, estacionamientos), atributos de ubicación (distrito, zona) y variables macroeconómicas (tipo de cambio, IPC). Estos modelos permiten estimar precios con mayor exactitud, reduciendo la subjetividad presente en las metodologías convencionales.

Por ello, este estudio tiene como objetivo desarrollar y evaluar un modelo predictivo basado en algoritmos de Machine Learning para estimar el precio de departamentos en el Perú, tomando como base datos estructurales, de ubicación y macroeconómicos correspondientes al periodo 1998–2025.

La relevancia de este enfoque radica en que puede mejorar la objetividad en las tasaciones, optimizar el acceso al crédito hipotecario, reducir asimetrías de información y aportar evidencia empírica para la toma de decisiones en el mercado inmobiliario peruano. Asimismo, contribuye a la modernización del sector mediante la incorporación de prácticas alineadas con las tendencias tecnológicas internacionales.

1.1. ANTECEDENTES

El análisis del estado del arte revela una transición tecnológica global en la valoración de activos inmobiliarios, desplazando los métodos tradicionales hacia enfoques basados en datos masivos, dado que la literatura académica internacional coincide en que los métodos clásicos enfrentan limitaciones severas ante la complejidad del mercado actual. En este sentido, Bin y Kruse (2006) establecieron que los modelos de precios hedónicos, si bien útiles, dependen de supuestos lineales que a menudo no logran capturar la realidad de los precios cuando se dispone de datos en línea. En respuesta a esto, la integración de *Big Data* ha transformado el sector, tal como sostienen Kok, Koponen y Martínez-Barbosa (2017), quienes afirman que la industria ha migrado de tasaciones manuales a "Modelos de Valoración Automatizada" (AVM) para superar la subjetividad humana y lograr estimaciones más consistentes. Esta superioridad algorítmica ha sido validada extensamente; por ejemplo, una revisión sistemática realizada por Munoz y de la Fuente (2022) concluye que los algoritmos de aprendizaje supervisado ofrecen una precisión significativamente mayor que las regresiones econométricas clásicas, mientras que Antipov y Pokryshevskaya (2012) demostraron específicamente que métodos como *Random Forest* superan a los árboles de decisión simples al capturar relaciones no lineales, hallazgos respaldados por Peterson y Flanagan (2009) y Chiang et al. (2021) en mercados norteamericanos y asiáticos, respectivamente.

A nivel regional, en Latinoamérica, la adopción de estas metodologías avanzadas es aún incipiente si se compara con los mercados de Norteamérica o Europa. Sin embargo, ya se documentan aplicaciones de análisis de datos inmobiliarios y aprendizaje automático en países como México, Chile y Perú, lo que indica un reconocimiento de la necesidad de modernizar los procesos de tasación.

Aterrizando esta problemática en el contexto latinoamericano y peruano, la adopción de estas tecnologías es incipiente pero urgente. Becerra y Rojas (2020) identificaron que la dependencia local de métodos comparativos tradicionales genera un alto grado de subjetividad y dificulta la estandarización de precios, una realidad abordada parcialmente por López y Torres (2021), quienes aplicaron técnicas de aprendizaje automático para viviendas en Lima Metropolitana, demostrando su viabilidad técnica pese a las dificultades de acceso a datos estructurados. Ante este panorama, el presente proyecto busca llenar el vacío existente mediante la integración de variables macroeconómicas oficiales, utilizando la data histórica del Banco Central de Reserva del Perú (1998-2025), lo que permite trascender la comparación física simple propuesta en los antecedentes locales y ajustar las valoraciones según la coyuntura económica temporal mediante algoritmos como *K-Nearest Neighbors*.

1.2. PLANTEAMIENTO DEL PROBLEMA

El mercado inmobiliario peruano desempeña un rol fundamental en el desarrollo económico y social del país, debido a su impacto directo en la inversión privada, la generación de empleo, el acceso a vivienda digna y la planificación urbana. En los últimos años, el sector construcción ha representado cerca del 5% del PBI nacional (Ministerio de Vivienda, 2023), mientras que el déficit habitacional supera las 1.8 millones de viviendas, lo que evidencia la necesidad creciente de contar con mecanismos eficientes y objetivos para la valoración de propiedades. Asimismo, en Lima Metropolitana, los precios han mostrado variaciones considerables: el costo del metro cuadrado puede ser hasta 350% mayor en distritos como San Isidro o Miraflores respecto a distritos periféricos como San Juan de Lurigancho o Comas (ASEI, 2024), lo cual refleja la fuerte heterogeneidad del mercado.

A pesar de esta relevancia económica, la tasación inmobiliaria peruana sigue basándose principalmente en métodos comparativos tradicionales, dependientes de la experiencia del tasador y de la selección de propiedades similares, lo que introduce subjetividad y dificulta la estandarización de precios (Becerra & Rojas, 2020). Además de esta subjetividad, persisten limitaciones estructurales, temporales y de información que afectan la precisión de las valoraciones.

Entre los principales problemas se identifican:

1. **Heterogeneidad espacial:** Los precios varían significativamente entre distritos, influenciados por la infraestructura, la accesibilidad y la disponibilidad de servicios urbanos.
2. **Volatilidad temporal:** Desde 1998, los precios de viviendas en Lima Metropolitana han sido afectados por fluctuaciones en el tipo de cambio, la inflación (IPC) y choques económicos externos, generando ciclos de expansión y contracción.
3. **Limitaciones en los registros:** La información disponible no integra de manera sistemática datos micro (propiedades individuales) con datos macroeconómicos (condiciones económicas nacionales), reduciendo la precisión de las estimaciones de valor.

4. **Ausencia de herramientas predictivas automatizadas:** A pesar del avance internacional en modelos de predicción basados en Machine Learning, la mayoría de las instituciones financieras peruanas no han implementado estos sistemas, desaprovechando su capacidad para modelar relaciones no lineales y temporales.

A ello se suma un vacío científico y tecnológico importante: no existen estudios locales que integren datos macroeconómicos del BCRP con características físicas y de ubicación de viviendas dentro de un modelo predictivo basado en Machine Learning, lo cual limita la generación de tasaciones objetivas, reproducibles y basadas en evidencia empírica.

¿Cómo predecir el precio de venta de viviendas en el Perú (1998–2025) integrando características físicas, variables de ubicación y datos macroeconómicos mediante algoritmos de Machine Learning, con el fin de mejorar la precisión y reducir la subjetividad en las tasaciones inmobiliarias?

Esta problemática se relaciona directamente con el objetivo general del estudio, orientado a desarrollar y evaluar un modelo predictivo automatizado para estimar precios de viviendas, así como con los objetivos específicos, que buscan analizar las variables determinantes, comparar algoritmos de aprendizaje supervisado e identificar el modelo con mejor rendimiento. De esta manera, el estudio se alinea con la necesidad de modernizar el proceso de tasación en el Perú, aportando una herramienta que contribuya a una mayor transparencia, eficiencia y competitividad en el mercado inmobiliario.

1.3.OBJETIVOS

Objetivo General: Desarrollar y evaluar un modelo predictivo basado en algoritmos de Machine Learning que permita estimar el precio de venta de departamentos en el Perú (1998–2025), integrando características físicas, variables de ubicación y componentes macroeconómicos, con el fin de mejorar la precisión y reducir la subjetividad en las tasaciones inmobiliarias.

Objetivos Específicos

1. Recolectar y estructurar un conjunto de datos integrado que combine información macroeconómica del BCRP con características físicas y de ubicación de los departamentos en Lima Metropolitana.

2. Analizar la relación estadística y comportamental entre las variables micro (propiedad), macro (economía) y temporales (año, tendencias), para identificar los factores que influyen significativamente en el precio de venta.
3. Aplicar y comparar diferentes algoritmos de aprendizaje supervisado, tales como Regresión Lineal, Random Forest, Gradient Boosting y Redes Neuronales, mediante métricas como RMSE y R^2 .
4. Seleccionar el modelo con mayor capacidad predictiva, justificando su rendimiento a través de una evaluación rigurosa con técnicas de validación cruzada y análisis de errores.
5. Construir un modelo predictivo automatizado que permita estimar el valor de departamentos nuevos o existentes, contribuyendo a una tasación más objetiva, reproducible y basada en evidencia empírica.

II. MARCO TEÓRICO

2.

2.1. HERRAMIENTAS DE INGENIERÍA

El desarrollo de un modelo predictivo para la estimación de precios inmobiliarios requiere integrar diversas herramientas de ingeniería de datos y aprendizaje automático que permitan gestionar información histórica, analizar patrones y construir modelos interpretables. En este proyecto se emplearán herramientas de código abierto en Python, seleccionadas por su confiabilidad, capacidad de integración y soporte científico-académico.

Las principales herramientas son:

- Python (v3.8+): Python ha sido seleccionado como el lenguaje principal debido a que es uno de los lenguajes más utilizados en ciencia de datos y Machine Learning gracias a su eficiencia, amplia comunidad, soporte académico y librerías optimizadas para el análisis numérico. Según Müller & Guido (2017), Python se ha consolidado como el estándar en el desarrollo de modelos predictivos por su facilidad de integración y desempeño robusto en tareas de aprendizaje automático.
- Pandas y NumPy: Para la manipulación de datos, se utilizan Pandas y NumPy, debido a su capacidad para procesar grandes volúmenes de datos tabulares de manera eficiente. McKinney (2018) destaca que Pandas facilita operaciones estructuradas y limpieza de datos de forma significativamente más rápida y confiable que herramientas tradicionales como Excel.
- Matplotlib, Seaborn y Plotly: Para la exploración visual de los datos se emplean Matplotlib y Seaborn, ya que permiten representar patrones, distribución de precios y correlaciones entre variables de forma clara para facilitar la interpretación del modelo. Waskom (2021) señala que Seaborn está especialmente diseñado para análisis estadístico visual dentro del flujo de trabajo de Machine Learning.
- Scikit-learn: se utiliza para el entrenamiento de algoritmos de aprendizaje supervisado debido a que es una de las bibliotecas más estandarizadas en entornos académicos y profesionales. Como lo indican Pedregosa et al. (2011), esta librería ofrece implementaciones de modelos estadísticos altamente optimizadas y evaluadas en benchmarks internacionales.

- Statsmodels: útil para análisis econométricos complementarios, verificación de supuestos y regresiones OLS con diagnóstico estadístico.
- Entorno de desarrollo: Jupyter Notebook o Google Colab, El entorno de desarrollo utilizado permite integrar código, análisis y resultados gráficos en un mismo archivo, garantizando trazabilidad y reproducibilidad del proceso experimental. Kluyver et al. (2016) demuestran que Jupyter facilita la documentación científica y la colaboración dentro de proyectos de ciencia de datos.

Estas herramientas conforman una arquitectura técnica flexible que facilita un flujo de trabajo completo: desde la adquisición y depuración de datos hasta la construcción, validación y comparación de modelos predictivos. Su principal ventaja radica en que permiten analizar variables estructurales (superficie, habitaciones, baños, antigüedad) junto con indicadores macroeconómicos (tipo de cambio, IPC), lo que enriquece el modelado del precio de venta.

Entre sus limitaciones, se considera que el tiempo de ejecución de algunos procesos —como la selección recursiva de características (RFE) o la optimización de hiperparámetros— puede ser elevado en grandes volúmenes de datos, por lo que se recomienda aplicar muestreos o técnicas de validación más eficientes.

TABLA 1

COMPARATIVA DE MODELOS DE MACHINE LEARNING

Característica	Regresión Lineal Múltiple (RLM)	Árbol de Decisión (Regressor)	K-Nearest Neighbors (KNN)
Tipo de Modelo	Lineal. Asume una relación aditiva y lineal entre las variables independientes y la dependiente.	No Lineal. Modela relaciones complejas mediante particiones recursivas del espacio de características.	No Lineal. Basado en instancia (vecindad), no asume una forma funcional específica.
Interpretabilidad	Alta. Los coeficientes (β) indican la magnitud y dirección del impacto de cada variable ² .	Alta. El modelo es una serie de reglas "si-entonces" que pueden ser visualizadas y son fáciles de entender ³ .	Baja/Media. La predicción se basa en un promedio de vecinos, pero no ofrece un coeficiente claro sobre el impacto de las variables.
Sensibilidad a la Escala	Baja. No es sensible a la escala de las variables, aunque el escalado puede ayudar a la interpretación de coeficientes.	Nula. Totalmente inmune a la escala de las características, ya que las decisiones se basan en puntos de corte (splits).	Muy Alta. Críticamente dependiente del escalado. Variables con rangos más amplios dominarán la métrica de distancia ⁴ (como se menciona en la propia literatura del proyecto ⁵).
Manejo de Outliers	Alta Sensibilidad. Los valores atípicos pueden influir desproporcionadamente en el ajuste de la línea de regresión.	Robusto. Los <i>outliers</i> tienden a ser aislados en nodos hoja, teniendo un impacto menor en la estructura general del árbol.	Alta Sensibilidad. Los <i>outliers</i> pueden ser seleccionados erróneamente como "vecinos", distorsionando la predicción promedio.
Justificación de Uso	Establecer una línea base (baseline) y validar el modelo hedónico clásico ⁶ .	Capturar relaciones no lineales e interacciones complejas (ej. "si es de 200m ² Y está en 'Distrito X', el precio cambia") ⁷ .	Modelar patrones locales y de similitud. Útil para entender cómo propiedades "similares" se agrupan en precio ⁸⁸ .

2.2. ALGORITMOS

El desarrollo del modelo predictivo se fundamenta en la aplicación de **algoritmos de aprendizaje supervisado**, cuya finalidad es estimar el valor de venta de inmuebles a partir de variables estructurales, espaciales y macroeconómicas. En este estudio se implementaron tres algoritmos: **Regresión Lineal Múltiple**, **Árbol de Decisión (Decision Tree Regressor)** y **K-Nearest Neighbors (KNN)**, seleccionados por su capacidad para capturar relaciones lineales y no lineales entre los atributos del mercado inmobiliario.

A.-Regresión Lineal Múltiple

La **Regresión Lineal Múltiple (RLM)** permite modelar la relación entre una variable dependiente continua (precio de venta) y varias variables independientes (área, número de habitaciones, baños, antigüedad, ubicación, tipo de cambio, IPC).

El modelo matemático general es:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \epsilon$$

- Y : precio estimado del inmueble,
- X_i : variables predictoras,
- β_i : coeficientes que representan la influencia de cada variable,
- ϵ : término de error aleatorio.

El objetivo es minimizar la suma de los errores cuadráticos:

$$\min \sum (y_i - \hat{y}_i)^2$$

- y_i = valor real del precio
- $\hat{y}_i$ = valor estimado por el modelo
- Σ = sumatoria de los errores al cuadrado

Pseudocódigo:

```
1 1. Cargar los datos (X, y)
2 2. Dividir en conjuntos de entrenamiento (80%) y prueba (20%)
3 3. Ajustar el modelo lineal usando mínimos cuadrados ordinarios
4 4. Calcular coeficientes  $\beta$  y el intercepto
5 5. Generar predicciones ( $\hat{y}$ )
6 6. Evaluar con métricas: MAE, RMSE y  $R^2$ 
7
```

B.-Árbol de Decisión Regresor

El **Árbol de Decisión** divide los datos en subconjuntos homogéneos según los valores de las variables predictoras. En cada nodo se selecciona la característica que produce la mayor reducción del error cuadrático medio (MSE):

Función de error utilizada en cada división del árbol:

$$\text{MSE} = (1/N) * \sum (y_i - \hat{y}_i)^2$$

- MSE = error cuadrático medio
- N = número total de observaciones en el nodo
- y_i = valor real
- $\hat{y}_i$ = valor promedio de las observaciones en ese nodo

Criterio de selección:

Se elige la variable y el punto de corte que generen la mayor reducción del MSE en cada división.

El árbol continúa dividiéndose hasta alcanzar un criterio de parada, como una profundidad máxima o un número mínimo de observaciones por nodo.

Ventajas: captura relaciones no lineales y permite interpretar la importancia de las variables.

Desventajas: riesgo de sobreajuste si no se poda adecuadamente.

Pseudocódigo:

```
1 1. Cargar datos (X, y)
2 2. Para cada variable candidata:
3     Calcular la reducción del MSE si se realiza una división
4 3. Seleccionar la división que minimice el MSE
5 4. Repetir recursivamente en cada subnodo
6 5. Detener cuando la profundidad > max_depth o MSE < umbral
7 6. Promediar valores de las hojas para predecir
8
9
```

c) K-Nearest Neighbors (KNN)

El modelo **KNN Regressor** estima el precio de una propiedad considerando los precios de las k propiedades más similares según una métrica de distancia (euclidiana):

Ecuación de predicción:

$$\hat{y} = (1/k) * \sum (y_i)$$

- $\hat{y}$ = valor estimado del nuevo inmueble
- y_i = precios reales de las k viviendas más cercanas
- k = número de vecinos seleccionados
- **Cálculo de la distancia euclidiana:**

$$d(x, x_i) = \sqrt{\sum (x_j - x_{ij})^2}$$

donde:

- $d(x, x_i)$ = distancia entre la vivienda a estimar y una vivienda del conjunto de datos
- x_j = valor de la variable j para la nueva vivienda
- x_{ij} = valor de la variable j para la vivienda i donde y_i son los valores de las viviendas más cercanas al nuevo registro.

Ventajas: sencillo, no requiere entrenamiento extenso.

Desventajas: sensible a la escala de los datos y costoso con grandes volúmenes.

Pseudocódigo:

```
1 1. Normalizar los datos (X)
2 2. Definir valor de k
3 3. Para cada nueva propiedad:
4   a. Calcular distancia a todos los puntos del conjunto de entrenamiento
5   b. Seleccionar los k vecinos más cercanos
6   c. Promediar sus valores de precio
7 4. Evaluar con métricas MAE, RMSE, R²
8
```

III. METODOLOGÍA

3.1. MATERIALES Y MÉTODOS UTILIZADOS

DATOS:

El conjunto de datos utilizado en este proyecto proviene de diversas fuentes confiables:

- **Banco Central de Reserva del Perú (BCRP):** Se utilizarán los indicadores históricos de precios de venta de inmuebles, tipo de cambio, IPC, y precios constantes publicados por el BCRP desde 1998 hasta 2025. Estos datos permitirán analizar las tendencias a largo plazo en el mercado inmobiliario peruano.
- **Características de las propiedades:** Se incluirán atributos físicos de las propiedades como la superficie (en m²), número de habitaciones, baños, antigüedad, y ubicación geográfica (distrito), que son factores clave para la estimación del valor de los inmuebles.
- **Variables macroeconómicas:** Las tasas de interés, tipo de cambio, y otras variables relacionadas con la economía que puedan influir en los precios de los inmuebles también serán consideradas en el análisis.

Herramientas de Software:

Se emplearán herramientas comunes en la ciencia de datos y aprendizaje automático para desarrollar el modelo predictivo:

- **Python (v3.8+):** Este lenguaje será el principal para el análisis de datos y desarrollo del modelo predictivo.
- **Bibliotecas de Python:**
 - **Pandas y NumPy:** Para la manipulación y limpieza de datos, y la creación de nuevas variables.
 - **Scikit-learn:** Para la implementación de los modelos de Machine Learning como regresión lineal, árboles de decisión y KNN.
 - **Matplotlib y Seaborn:** Para la visualización de los resultados y gráficos exploratorios.
 - **Statsmodels:** Para análisis econométricos y evaluación de los modelos.
 - **Entorno de Desarrollo: Google Colab o Jupyter Notebook** serán utilizados para la ejecución del código interactivo y la presentación de resultados.

Hardware:

- **Computadora** con al menos **8 GB de RAM**, que es necesario para manejar grandes volúmenes de datos y entrenar los modelos de Machine Learning de manera eficiente.
- **Conexión a Internet:** Para acceder a bases de datos y APIs públicas.

Métodos

1. Recolección de Datos:

Se utilizarán los datos históricos del **BCRP**, y se consolidarán en un único **DataFrame** utilizando **Pandas**. Esto permitirá el análisis y la creación de un conjunto de datos unificado para el modelado predictivo.

2. Preprocesamiento de Datos:

○ Limpieza de datos:

Eliminación de registros incompletos y nulos, especialmente en variables críticas como el **precio de venta**.

Establecer consistencia en las columnas, como las fechas y las categorías de los distritos.

○ Transformación de variables:

Se crearán nuevas variables como **año**, **trimestre**, y **mes** a partir de las fechas, y se convertirán las variables categóricas (por ejemplo, el distrito) en variables numéricas mediante codificación.

○ Detección de outliers:

Se utilizarán métodos estadísticos como el **IQR (Interquartile Range)** para identificar y manejar los valores atípicos que puedan afectar la precisión del modelo.

○ Codificación de variables:

Variables como **distrito** y **tipo de cambio** se codificarán para que puedan ser usadas en los algoritmos de Machine Learning.

3. Ingeniería de Características:

Selección de características:

Las variables seleccionadas para el modelo incluirán:

- **Características estructurales:** Superficie, número de habitaciones, baños, antigüedad.
- **Características de ubicación:** Distrito, zona, y proximidad a servicios clave como transporte y centros comerciales.
- **Variables macroeconómicas:** Tipo de cambio, IPC, tasas de interés.
- **Escalado de características:**

Se utilizará el **StandardScaler** para normalizar las variables numéricas, asegurando que todas las características tengan una contribución equitativa al modelo.

4. Modelado:

En esta fase, se entrenarán diferentes modelos de Machine Learning:

- **Regresión Lineal Múltiple:** Para modelar la relación lineal entre el precio de venta y las características de la propiedad y macroeconómicas.

- **Árboles de Decisión (Decision Tree):** Para modelar relaciones no lineales entre las variables. Este modelo es interpretativo y puede capturar interacciones complejas entre las variables.
- **K-Nearest Neighbors (KNN):** Este modelo será útil para capturar relaciones no lineales y patrones espaciales de las propiedades en el mercado inmobiliario.

Los modelos serán entrenados utilizando el **80% de los datos** para el entrenamiento y el **20% restante para prueba**.

5. Evaluación del Modelo:

Los modelos se evaluarán utilizando las siguientes métricas:

- **MAE (Error Absoluto Medio):** La media de las diferencias absolutas entre las predicciones y los valores reales.
- **RMSE (Raíz del Error Cuadrático Medio):** La desviación estándar de las diferencias cuadradas entre las predicciones y los valores reales.
- **R² (Coeficiente de Determinación):** Para medir la proporción de variabilidad del precio que el modelo es capaz de explicar.

6. Visualización y Reportes:

Se presentarán los resultados mediante visualizaciones:

- **Gráficos de dispersión** para observar las relaciones entre las características de las propiedades y el precio de venta.
- **Mapas de calor** para visualizar la correlación entre las variables y el precio de venta.
- **Gráficos de barras** para representar la importancia de las variables en el modelo.

3.2. PROCESO DE DESARROLLO DEL PROYECTO

Describe las fases de acuerdo con la metodología seleccionada.

Se debe adjuntar las evidencias (algoritmos, formular, fotografías de prototipos, etc)

El desarrollo del proyecto se ejecutó siguiendo un flujo de trabajo de Ciencia de Datos estructurado en cinco fases secuenciales, alineadas con las mejores prácticas de Machine Learning. A continuación, se detalla cada fase con sus respectivas evidencias de implementación.

Fase 1: Recolección e Integración de Datos

En esta etapa se consolidaron las fuentes de información heterogéneas. Se unificaron los registros transaccionales de inmuebles (microdatos) con las series de tiempo macroeconómicas proporcionadas por el Banco Central de Reserva del Perú (BCRP).

- **Actividad:** Fusión de datasets mediante la fecha de venta para asignar el Tipo de Cambio e IPC correspondiente a cada transacción inmobiliaria.
- **Evidencia 1 (Captura de Datos):**

(Aquí debes insertar una captura de pantalla de tu DataFrame en Python mostrando las primeras 5 filas con `df.head()`, donde se vean columnas como 'Area', 'Distrito' junto a 'TC_Venta' e 'IPC').

Fase 2: Preprocesamiento y Limpieza

Se aplicaron técnicas estadísticas para asegurar la calidad de los datos antes del modelado.

- **Tratamiento de Valores Nulos:** Se eliminaron registros incompletos en variables críticas como el precio de venta para evitar sesgos.
- **Detección de Outliers:** Se utilizó el Rango Intercuartílico (IQR) para filtrar valores atípicos que podrían distorsionar el entrenamiento, especialmente en la Regresión Lineal.

Evidencia 2 (Algoritmo de Limpieza):

```
# Evidencia de código para filtrado de Outliers (IQR)
Q1 = df['Precio'].quantile(0.25)
Q3 = df['Precio'].quantile(0.75)
IQR = Q3 - Q1
df_limpio = df[~((df['Precio'] < (Q1 - 1.5 * IQR)) | (df['Precio'] > (Q3 + 1.5 * IQR)))]
```

Para desarrollar el apartado **3.2. Proceso de Desarrollo del Proyecto**, debemos estructurar las actividades que realizaron siguiendo un flujo lógico de Ciencia de Datos (similar a la metodología CRISP-DM, que es el estándar implícito en su informe).

Aquí tienes una propuesta de redacción formal para tu informe. He incluido los lugares exactos donde debes poner tus **evidencias** (fórmulas matemáticas extraídas de tu marco teórico y fragmentos de código/capturas).

3.2. PROCESO DE DESARROLLO DEL PROYECTO

El desarrollo del proyecto se ejecutó siguiendo un flujo de trabajo de Ciencia de Datos estructurado en cinco fases secuenciales, alineadas con las mejores prácticas de Machine Learning. A continuación, se detalla cada fase con sus respectivas evidencias de implementación.

Fase 1: Recolección e Integración de Datos

En esta etapa se consolidaron las fuentes de información heterogéneas. Se unificaron los registros transaccionales de inmuebles (microdatos) con las series de tiempo macroeconómicas proporcionadas por el Banco Central de Reserva del Perú (BCRP).

- **Actividad:** Fusión de datasets mediante la fecha de venta para asignar el Tipo de Cambio e IPC correspondiente a cada transacción inmobiliaria.
- **Evidencia 1 (Captura de Datos):**

(Aquí debes insertar una captura de pantalla de tu DataFrame en Python mostrando las primeras 5 filas con `df.head()`, donde se vean columnas como 'Area', 'Distrito' junto a 'TC_Venta' e 'IPC').

Fase 2: Preprocesamiento y Limpieza

Se aplicaron técnicas estadísticas para asegurar la calidad de los datos antes del modelado.

- **Tratamiento de Valores Nulos:** Se eliminaron registros incompletos en variables críticas como el precio de venta para evitar sesgos.
- **Detección de Outliers:** Se utilizó el Rango Intercuartílico (IQR) para filtrar valores atípicos que podrían distorsionar el entrenamiento, especialmente en la Regresión Lineal.

Evidencia 2 (Algoritmo de Limpieza):

```
Python
# Evidencia de código para filtrado de Outliers (IQR)
Q1 = df['Precio'].quantile(0.25)
Q3 = df['Precio'].quantile(0.75)
IQR = Q3 - Q1
df_limpio = df[~((df['Precio'] < (Q1 - 1.5 * IQR)) | (df['Precio'] > (Q3 + 1.5 * IQR)))]
```

Fase 3: Ingeniería de Características

Se transformaron las variables para adaptarlas a los requerimientos matemáticos de los algoritmos seleccionados.

- **Codificación:** Las variables categóricas como "Distrito" fueron convertidas a valores numéricos para ser procesadas por los modelos.
- **Escalado:** Se aplicó `StandardScaler` a las variables numéricas (Área, Habitaciones, IPC) para normalizar los rangos, paso crítico para el correcto funcionamiento del algoritmo KNN, que es sensible a la escala.

Fase 4: Modelado y Entrenamiento

Se implementaron y entrenaron los tres algoritmos seleccionados utilizando el 80% de los datos para entrenamiento y el 20% para validación.

A. Regresión Lineal Múltiple Se buscó minimizar la suma de los errores cuadráticos para encontrar la relación lineal óptima.

- **Evidencia (Formulación Matemática):**

$$\min \sum (y_i - \hat{y}_i)^2$$

B. Árbol de Decisión (Decision Tree Regressor) El modelo aprendió reglas de decisión no lineales dividiendo los datos para reducir el error cuadrático medio (MSE) en cada nodo.

- **Evidencia (Fórmula de Costo):**

$$MSE = \frac{1}{N} \sum (y_i - \hat{y}_i)^2$$

C. K-Nearest Neighbors (KNN) Se calculó la predicción basándose en la similitud espacial y de características mediante la distancia euclidiana.

- **Evidencia (Algoritmo de Distancia):**

$$d(x, x_i) = \sqrt{\sum (x_j - x_{ij})^2}$$

IV. RESULTADOS

4.1. JUSTIFICACIÓN DEL PROYECTO

La selección de los algoritmos de Inteligencia Artificial para este proyecto no fue arbitraria, sino el resultado de un proceso riguroso de validación teórica y experimental. A continuación, se justifica la aplicación de los modelos basándose en cuatro pilares fundamentales:

A. Justificación Teórica

El mercado inmobiliario de Lima presenta un comportamiento **no lineal**. Variables como el "Distrito" o la "Antigüedad" no afectan el precio de manera constante (una casa no vale necesariamente el doble si tiene el doble de habitaciones, ya que existen factores de saturación y ubicación).

Por esta razón, se justificó la implementación de tres familias de algoritmos distintos para capturar esta complejidad:

1. **Regresión Lineal Múltiple:** Como línea base estadística para medir relaciones directas.
2. **Árbol de Decisión (Decision Tree):** Para capturar reglas de decisión jerárquicas no lineales.

3. **K-Vecinos Más Cercanos (KNN):** Basado en la premisa teórica de la "Tasación por Comparación", donde el valor de un inmueble se estima mejor observando inmuebles similares cercanos en el espacio vectorial de características.

B. Experimentación

Para la fase experimental, se utilizó un conjunto de datos depurado de **84,528 registros** (periodo 2010-2025), aplicando una división estándar de **80% para entrenamiento** y **20% para pruebas**. Esta metodología garantizó que los algoritmos fueran evaluados con datos desconocidos, simulando un escenario real de tasación y evitando el *overfitting* (sobreajuste).

C. Pruebas de Rendimiento

Se sometieron los tres algoritmos a pruebas comparativas utilizando las métricas de **Coefficiente de Determinación (R^2)** y **Raíz del Error Cuadrático Medio (RMSE)**. Los resultados obtenidos en la fase de modelado fueron los siguientes:

- **Regresión Lineal:** Mostró el rendimiento más bajo ($R^2 \approx 0.719$), evidenciando que un enfoque puramente lineal es insuficiente para la complejidad del mercado limeño.
- **Árbol de Decisión:** Mejoró la precisión ($R^2 \approx 0.741$), pero mostró limitaciones en la generalización de precios continuos.
- **K-Nearest Neighbors (KNN):** Obtuvo el mejor desempeño con un **R^2 de 0.789** y el menor error cuadrático (RMSE), demostrando ser el algoritmo más robusto para este dominio específico.

D. Validación y Selección Final

La validación final confirma que el algoritmo **KNN (K-Nearest Neighbors)** es el más idóneo para el proyecto. Su superioridad técnica se justifica porque el mercado inmobiliario funciona por **similitud**: un departamento en Miraflores se parece más a otros departamentos en Miraflores con metraje similar que a un promedio general de la ciudad.

El algoritmo KNN logró interpretar correctamente estas agrupaciones locales, ofreciendo predicciones con una precisión cercana al **79%**, lo cual es altamente aceptable para un sistema de soporte a la decisión en ingeniería de

sistemas. Por tanto, el desarrollo del capítulo de resultados se centrará en la implementación y explotación de este modelo ganador.

4.2. RESULTADOS OBTENIDOS DEL PROYECTO EN BASE A LOS OBJETIVOS

A continuación, se documenta la evidencia técnica y funcional de la solución implementada.

1. Para la sección de Depuración de Datos (OE1)

Para garantizar la calidad del entrenamiento, se aplicó un proceso riguroso de limpieza de datos sobre la base original de precios inmobiliarios. Se utilizaron técnicas estadísticas como el Rango Intercuartílico (IQR) para identificar y eliminar valores atípicos (outliers) que podrían distorsionar las predicciones, además de descartar registros con valores nulos en variables críticas.

Como se observa en la siguiente evidencia de ejecución, este proceso permitió refinar la muestra, eliminando inconsistencias y ruido estadístico:



Interpretación: "El sistema redujo la base de 88,258 a 84,528 registros válidos, descartando aproximadamente 3,730 datos erróneos, lo que asegura una base sólida para el aprendizaje del modelo."

2. Para la sección de Implementación (OE2)

Se implementó el algoritmo K-Nearest Neighbors (KNN) utilizando un Pipeline de procesamiento automatizado. Debido a que el KNN calcula distancias matemáticas, fue fundamental incluir un paso de estandarización (StandardScaler) para poner todas las variables numéricas en la misma escala.

El modelo se configuró con un hiperparámetro de **7 vecinos (n_neighbors=7)** y la métrica de distancia euclidiana, tal como se muestra en el código fuente desarrollado:

```
# IMPLEMENTACIÓN DEL MODELO GANADOR: K-NEAREST NEIGHBORS (KNN)
from sklearn.neighbors import KNeighborsRegressor
from sklearn.pipeline import Pipeline

# Configuración del Pipeline Óptimo
# 1. Preprocesamiento: Escalado de variables (Crítico para KNN)
# 2. Modelo: KNN con 7 vecinos (k=7) definido experimentalmente
modelo_final = Pipeline(steps=[
    ('preprocessor', preprocessor), # Tu transformador de datos definido antes
    ('knn', KNeighborsRegressor(n_neighbors=7, metric='euclidean'))
])

# Entrenamiento con el set completo de datos
modelo_final.fit(X_train, y_train)

# Validación de métricas
print(f"Precisión Final (R2): {modelo_final.score(X_test, y_test):.4f}")

Precisión Final (R2): 0.7894
```

```

import matplotlib.pyplot as plt
import seaborn as sns
import pandas as pd
import numpy as np

# --- BLOQUE GRÁFICO ESPECÍFICO PARA KNN ---

# Asegúrate de tener 'modelo_final' (tu Pipeline KNN) ya entrenado
# Si no, corre el bloque de entrenamiento del "Ganador" que te di antes.

# 1. GRÁFICO DE PRECISIÓN: REAL VS PREDICHO
# Este gráfico demuestra la potencia del R2 de 0.79
y_pred_knn = modelo_final.predict(X_test)

plt.figure(figsize=(14, 6))

# Subplot 1: Real vs Predicho
plt.subplot(1, 2, 1)
sns.scatterplot(x=y_test, y=y_pred_knn, alpha=0.5, color='blue', edgecolor='k')
# Línea de perfección (Donde debería estar si fuera 100% perfecto)
max_val = max(y_test.max(), y_pred_knn.max())
min_val = min(y_test.min(), y_pred_knn.min())
plt.plot([min_val, max_val], [min_val, max_val], 'r--', lw=2, label='Predicción Perfecta')

plt.title(f'Precisión del Modelo KNN (R² = {modelo_final.score(X_test, y_test):.2F})', fontsize=12)
plt.xlabel('Precio Real (USD)', fontsize=10)
plt.ylabel('Precio Predicho por KNN (USD)', fontsize=10)
plt.legend()
plt.grid(True, alpha=0.3)

# 2. GRÁFICO DE COMPORTAMIENTO: LA "FORMA" DEL KNN
# Vamos a aislar un Distrito para ver cómo "piensa" el KNN
plt.subplot(1, 2, 2)

# Elegimos un distrito representativo y filtramos datos reales
distrito_demo = 'MiraFloras' # 0 el distrito que prefieras
datos_distrito = df[df['Distrito'] == distrito_demo]

# Graficamos los puntos reales de ese distrito
sns.scatterplot(data=datos_distrito, x='Area_m2', y='Precio',
               alpha=0.4, color='gray', label='Datos Reales')

# Simulamos predicción KNN solo variando el Área (Ceteris Paribus)
# Mantenemos fijas las otras variables en su promedio
areas_simuladas = np.linspace(datos_distrito['Area_m2'].min(), datos_distrito['Area_m2'].max(), 100)
datos_simulados = pd.DataFrame({
    'Area_m2': areas_simuladas,
    'Habitaciones': [datos_distrito['Habitaciones'].median()] * 100,
    'Baños': [datos_distrito['Baños'].median()] * 100,
    'Antigüedad': [datos_distrito['Antigüedad'].median()] * 100,
    'Distrito': [distrito_demo] * 100,
    'TC_Venta': [df['TC_Venta'].mean()] * 100,
    'IPC': [df['IPC'].mean()] * 100
})


# Predicimos la curva
linea_knn = modelo_final.predict(datos_simulados)

# Pintamos la línea del KNN
plt.plot(areas_simuladas, linea_knn, color='red', lw=3, label='Curva de Ajuste KNN')

plt.title(f'Comportamiento No Lineal del KNN en {distrito_demo}', fontsize=12)
plt.xlabel('Área (m²)', fontsize=10)
plt.ylabel('Precio Estimado (USD)', fontsize=10)
plt.legend()
plt.grid(True, alpha=0.3)

plt.tight_layout()
plt.show()

```



3. Para la sección de Resultados y Validación (OE3)

Para validar la eficacia del modelo propuesto, se sometió a una prueba comparativa frente a otros algoritmos tradicionales (Regresión Lineal y Árboles de Decisión). Se utilizaron métricas estándar de la industria: MAE (Error Absoluto Medio), RMSE (Raíz del Error Cuadrático Medio) y R^2 (Coeficiente de determinación).

La tabla de resultados obtenida demuestra la superioridad técnica del modelo KNN:

```

# BLOQUE 5: Entrenamiento y Evaluación Comparativa

# Diccionario de modelos
modelos = {
    "Regresión Lineal": LinearRegression(),
    "Árbol de Decisión": DecisionTreeRegressor(random_state=42, max_depth=10), # Limitamos profundidad para evitar overfit
    "K-Nearest Neighbors": KNeighborsRegressor(n_neighbors=7)
}

resultados = []

for nombre, modelo in modelos.items():
    # Crear Pipeline
    pipeline = Pipeline(steps=[('preprocessor', preprocessor),
                                ('model', modelo)])

    # Entrenar
    pipeline.fit(X_train, y_train)

    # Predecir
    y_pred = pipeline.predict(X_test)

    # Métricas
    mae = mean_absolute_error(y_test, y_pred)
    rmse = np.sqrt(mean_squared_error(y_test, y_pred))
    r2 = r2_score(y_test, y_pred)

    resultados.append([nombre, mae, rmse, r2])

# Crear Tabla de Resultados
df_resultados = pd.DataFrame(resultados, columns=["Modelo", "MAE (Error Absoluto)", "RMSE (Raíz Error Cuadrático)", "R2 (Precisión)"])


# EVIDENCIA FINAL (Tabla Comparativa)
print("--- COMPARACIÓN DE RENDIMIENTO ---")
print(df_resultados)

--- COMPARACIÓN DE RENDIMIENTO ---

```

	Modelo	MAE (Error Absoluto)	RMSE (Raíz Error Cuadrático)	R2 (Precisión)
0	Regresión Lineal	27142.695958	36797.169510	0.719270
1	Árbol de Decisión	26272.038450	35305.506105	0.741569
2	K-Nearest Neighbors	22564.071726	31874.816002	0.789353

Interpretación: "El modelo KNN obtuvo un R^2 de 0.789, lo que significa que el sistema es capaz de explicar el 78.9% de la variabilidad de los precios del mercado. Además, presentó el error más bajo (RMSE = 31,874), superando significativamente a la Regresión Lineal, que mostró mayor margen de error."



4. Para la sección de Funcionamiento General (OG)

Finalmente, para verificar la funcionalidad del sistema en un entorno de producción, se simularon tres escenarios de tasación con características y ubicaciones distintas (Zona Norte, Zona Centro y Zona Top). El objetivo fue confirmar que el modelo discrimina correctamente el valor según el distrito y el metraje.

Los resultados de las predicciones generadas por el sistema son los siguientes:

```
[15] # Creamos 3 casos de prueba manuales
✓ 0 s casos_prueba = pd.DataFrame({
    'Area_m2': [60, 120, 250],          # Pequeño, Mediano, Grande
    'Habitaciones': [2, 3, 5],
    'Baños': [1, 2, 4],
    'Antigüedad': [5, 10, 2],          # Nuevo, Usado, Lujó
    'Distrito': ['Los Olivos', 'Jesus Maria', 'San Isidro'], # Periferia, Medio, Top
    'TC_Venta': [3.75, 3.75, 3.75],    # Tipo de cambio actual
    'IPC': [df['IPC'].iloc[-1], df['IPC'].iloc[-1], df['IPC'].iloc[-1]] # IPC actual
})

predicciones = modelo_final.predict(casos_prueba)

# Mostramos resultados bonitos
for i, precio in enumerate(predicciones):
    print(f"Caso {i+1} ({casos_prueba.iloc[i]['Distrito']}, {casos_prueba.iloc[i]['Area_m2']}m2): ${precio:,.2f}")

*** Caso 1 (Los Olivos, 60m2): $65,271.43
    Caso 2 (Jesus Maria, 120m2): $181,700.00
    Caso 3 (San Isidro, 250m2): $313,428.57
```

Interpretación: "El sistema asignó valoraciones coherentes con la realidad del mercado inmobiliario de Lima:

- Un departamento pequeño en **Los Olivos** fue tasado en **\$65k** (Gama económica).
- Un departamento mediano en **Jesús María** en **\$181k** (Gama media).
- Un inmueble grande en **San Isidro** superó los **\$313k** (Gama alta). Esto confirma que la Inteligencia Artificial ha aprendido correctamente los patrones de valoración inmobiliaria."

V. DISCUSIÓN Y CONCLUSIONES

5.1. DISCUSIÓN DE RESULTADOS CON LOS ANTECEDENTES

El presente estudio logró desarrollar un modelo predictivo basado en el algoritmo **K-Nearest Neighbors (KNN)** con un coeficiente de determinación (R^2) de **0.7894**, superando a la Regresión Lineal Múltiple ($R^2=0.7193$) y al Árbol de Decisión ($R^2=0.7415$)¹. Al contrastar estos hallazgos con la literatura revisada, se validan y extienden las siguientes premisas teóricas:

Superioridad del Machine Learning frente a modelos lineales:

Nuestros resultados corroboran empíricamente lo expuesto por Bin y Kruse (2006), quienes advertían que los modelos hedónicos tradicionales fallan al asumir relaciones lineales en un mercado inherentemente complejo². En nuestro experimento, la incapacidad de la Regresión Lineal para superar el umbral de precisión del 72% confirma que el mercado inmobiliario limeño presenta comportamientos no lineales que escapan a la econometría clásica³. Esto se

alineada directamente con la revisión sistemática de Munoz y de la Fuente (2022), cuyos hallazgos sobre la superioridad de los algoritmos de aprendizaje supervisado sobre los métodos estadísticos tradicionales se ven reflejados en la mejora del rendimiento obtenida al migrar a un modelo basado en instancias (KNN)⁴.

Validación de la Valoración Automatizada (AVM):

La implementación exitosa del pipeline automatizado responde a la necesidad planteada por Kok, Koponen y Martínez-Barbosa (2017) de transitar hacia Modelos de Valoración Automatizada (AVM) para eliminar la subjetividad humana⁵. A diferencia de los métodos manuales criticados en la literatura, nuestro modelo KNN logró objetivizar la tasación basándose puramente en la similitud vectorial de atributos, reduciendo el error de estimación (RMSE) a 31,874 USD⁶. Este resultado demuestra que es posible replicar la lógica de "comparables" del perito tasador, pero con la velocidad y consistencia del procesamiento de Big Data, tal como sugieren Antipov y Pokryshevskaya (2012) al destacar la eficacia de modelos computacionales para la valoración masiva⁷.

Aporte al contexto peruano y variables macroeconómicas:

En el ámbito nacional, la investigación aborda las limitaciones identificadas por Becerra y Rojas (2020) respecto a la subjetividad y falta de estandarización en las tasaciones en Perú⁸. Si bien López y Torres (2021) ya habían explorado el uso de ML en Lima Metropolitana ⁹, nuestro proyecto marca una diferencia significativa al integrar exitosamente variables macroeconómicas del BCRP (Tipo de Cambio e IPC)¹⁰. Los resultados sugieren que la inclusión de estas variables temporales fue determinante para que el modelo alcanzara un 79% de precisión, validando que el valor de un inmueble en Perú no es estático, sino que fluctúa con la coyuntura económica, un factor que los modelos puramente físicos de estudios previos no lograban capturar totalmente.

Importancia de la Calidad de Datos:

Finalmente, el proceso de depuración mediante el Rango Intercuartílico (IQR), que eliminó más de 3,700 registros atípicos¹¹, confirma que la calidad del dato es un prerequisite indispensable para el éxito de los algoritmos de similitud. Esto es consistente con la literatura sobre Real Estate Data Analysis, donde la presencia de outliers suele distorsionar severamente las métricas de distancia euclidiana utilizadas en algoritmos como KNN¹².

5.2. CONCLUSIONES POR OBJETIVO

Conclusión General

Se logró desarrollar y validar un modelo predictivo automatizado capaz de estimar el valor de mercado de departamentos en Lima Metropolitana. La integración de algoritmos de Machine Learning con variables

macroeconómicas del BCRP permitió reducir la incertidumbre en la tasación, obteniendo un sistema final basado en **K-Nearest Neighbors (KNN)** que explica el **78.94%** de la variabilidad de los precios ($R^2 \approx 0.79$). Esto confirma que la inteligencia artificial es una herramienta viable para objetivizar el proceso de valoración inmobiliaria en el Perú.

Conclusiones Específicas

1. Respecto al Objetivo Específico 1 (Recolección y Estructuración):
- Se consolidó exitosamente una base de datos robusta integrando registros transaccionales con indicadores económicos del Banco Central de Reserva del Perú (BCRP). La aplicación de técnicas de limpieza estadística, específicamente el filtro de Rango Intercuartílico (IQR), fue determinante para eliminar inconsistencias, depurando la muestra final a 84,528 registros de alta calidad, lo que garantizó la estabilidad del entrenamiento.
2. Respecto al Objetivo Específico 2 (Análisis de Variables):
- El análisis exploratorio y el preprocesamiento confirmaron que el precio de los inmuebles no depende únicamente de sus características físicas (área, habitaciones), sino que está fuertemente correlacionado con factores temporales y macroeconómicos (IPC y Tipo de Cambio). La estandarización de estas variables (StandardScaler) permitió que el modelo capturara correctamente la influencia de la inflación y la ubicación geográfica en el valor final.
3. Respecto al Objetivo Específico 3 (Comparación de Algoritmos):
- Tras someter a prueba tres enfoques distintos, se concluye que los modelos no lineales superan significativamente a los métodos tradicionales. Mientras que la Regresión Lineal Múltiple obtuvo un rendimiento base ($R^2 = 0.719$), los algoritmos basados en decisiones y proximidad demostraron una mejor adaptación a la complejidad del mercado, validando la hipótesis de que el sector inmobiliario no sigue un comportamiento puramente lineal.
4. Respecto al Objetivo Específico 4 (Selección del Modelo):

Se determinó que el algoritmo K-Nearest Neighbors (KNN) es el modelo con mayor capacidad predictiva para este caso de estudio. Su selección se justifica tanto métrica como teóricamente: alcanzó el menor error cuadrático medio (RMSE: 31,874 USD) y el mayor coeficiente de determinación (R^2 : 0.789). Esto demuestra que el enfoque de "vecindad" replica con mayor fidelidad la lógica de tasación por comparación de mercado que utilizan los peritos humanos.

5. Respecto al Objetivo Específico 5 (Automatización):

Se construyó un flujo de trabajo automatizado (Pipeline) funcional que permite tasar inmuebles en tiempo real. Las pruebas de simulación en distintos escenarios (Lima Top vs. Lima Norte) arrojaron valoraciones coherentes con la realidad comercial (ej. diferenciando correctamente precios entre San Isidro y Los Olivos para metrajes similares), cumpliendo con el propósito de entregar una herramienta tecnológica objetiva y reproducible.

VI. REFERENCIAS BIBLIOGRÁFICAS

Antipov, E. A., & Pokryshevskaya, E. B. (2012). *Mass appraisal of residential apartments: An application of Random Forest for valuation and a CART-based approach for model diagnostics*. Expert Systems with Applications, 39(2), 1772–1778. <https://doi.org/10.1016/j.eswa.2011.08.077>

Kok, N., Koponen, E.-L., & Martínez-Barbosa, C. A. (2017). *Big data in real estate? From manual appraisals to automated valuation*. Journal of Portfolio Management, 43(6), 202–211. <https://doi.org/10.3905/jpm.2017.43.6.202>

Bin, O., & Kruse, J. B. (2006). *Real estate valuation and the Internet: An hedonic pricing model using online data*. Journal of Real Estate Research, 28(4), 397–412.

Peterson, S., & Flanagan, A. (2009). *Neural network hedonic pricing models in mass real estate appraisal*. Journal of Real Estate Research, 31(2), 147–164.

Worzala, E., Lenk, M., & Silva, A. (1995). *An exploration of neural networks and its application to real estate valuation*. Journal of Real Estate Research, 10(2), 185–201.

Munoz, F., & de la Fuente, A. (2022). *Machine learning in real estate market prediction: A systematic review*. Heliyon, 8(4), e09345. <https://doi.org/10.1016/j.heliyon.2022.e09345>

Becerra, A., & Rojas, L. (2020). *Modelos predictivos aplicados al análisis del mercado inmobiliario peruano*. Revista de Ingeniería y Tecnología, 8(2), 55–67.

López, R., & Torres, P. (2021). *Aplicación del aprendizaje automático para la estimación de precios de viviendas en Lima Metropolitana*. Revista Peruana de Computación e Informática, 5(1), 32–44.

Chiang, Y.-H., Wong, F. K. W., & Liu, A. M. M. (2021). *Predicting housing prices with machine learning algorithms: Evidence from Asian markets*. International Journal of Strategic Property Management, 25(6), 546–561. <https://doi.org/10.3846/ijspm.2021.14156>

Banco Central de Reserva del Perú (BCRP). (2025). *Indicador de precios de venta de departamentos*. Recuperado de <https://www.bcrp.gob.pe/estadisticas/indicador-de-precios-de-venta-de-departamentos.html>

VII. ANEXOS

ANEXO 01: Certificados / Evidencia de culminación de curso IBM Watson de cada integrante del equipo









ANEXO 02: Fotografías de prototipos, algoritmos, producto mínimo viable (MVP), etc (resultado final)

Imagen 1: distribución de precios post-limpieza




Imagen 2: Tabla de resultado visual

	Area_m2	Habitaciones	Banos	Antiguedad	Distrito	TC_Venta	IPC	Precio_Predicho_USD	Escenario
0	60	2	1	5	San Miguel	3.750000	1.500000	56590.080000	Pequeño-Económico
1	80	3	2	10	Miraflores	3.750000	1.500000	140000.000000	Mediano-Estándar
2	100	3	2	0	San Isidro	3.800000	1.600000	150400.080000	Familiar
3	120	4	3	15	Santiago de Surco	3.800000	1.600000	113398.250000	Residencial
4	150	4	3	2	La Molina	3.850000	1.700000	124583.410000	Premium-Futuro

Imagen 3: Proyección de Valor de Mercado




Imagen 4: Modelo KNN




Imagen 5: Variables que definen el precio según el modelo





Imagen 6: Distribución de los Errores de Predicción:



La mayoría de los errores oscilan entre: \$-17821 y \$14678

Imagen 7: Variables que definen más el precio

Calculando importancia de variables (versión optimizada)...

